F1 데이터 정제 전략·처리 기준 Q&A

Oct 16, 2026 · @서정길

정제 전략 한눈에

원칙은 **근거가 있는 값만 고치고, 행은 지우지 않으며, 고친 이유를 모두 남긴다**입니다. 그 결과 오염 6종 120,873행에서 이슈 28,071건을 탐지했고, 1,357셀을 복구, 24,866건을 원천 특성으로 허용, 4행을 격리했습니다. FAIL 파일은 정제 전 5개에서 0개가 됐습니다.

1. **원본 보존:** CSV를 모두 문자열로 읽고 원본은 수정하지 않습니다. 행·컬럼 수, 컬럼 순서, SHA-256 체크섬을 명세와 대조합니다(bronze_manifest.csv).
2. **진단:** 표준사전의 진단코드 DQ001~DQ027로 결측·형식·키·관계·시간·구간을 검사합니다.
3. **근거 기반 복구:** 다른 파일·다른 세션·인접 랩처럼 데이터 안에 근거가 있을 때만 고칩니다. 중앙값 일괄 대체는 하지 않습니다.
4. **상태 기록:** 이슈마다 REPAIRED(복구), ACCEPTED(원천 특성 허용), OPEN(근거 부족) 중 하나를 남깁니다.
5. **격리:** 분석을 왜곡하는데 고칠 근거가 없는 행은 quarantine_flag=Y로 표시하고 따로 저장합니다.
6. **파일 판정:** ERROR 등급이 남으면 FAIL, OPEN이 남으면 REVIEW, 없으면 PASS입니다.
7. **재검증:** 정제 후 VC01~VC71 검사를 정제 전 값과 정제 후 값에 똑같이 돌리고, pandas와 MySQL 결과를 대조합니다(154개 검사, FAIL 12 → 0).

원칙	이유
근거 없는 값은 채우지 않는다	추정값이 섞이면 이후 분석 결과가 진짜 기록인지 구분할 수 없습니다.
행을 삭제하지 않는다	원본 행 = 유지 + 복구 + 격리로 대사할 수 있어야 누락이 없다는 걸 증명할 수 있습니다.
원본 값을 original_* 컬럼에 남긴다	복구가 틀렸을 때 되돌리고, 정제 전후 비교를 같은 검사로 돌릴 수 있습니다.
오류와 원천 특성을 구분한다	속도 결측 24,101건처럼 원래 없는 값을 오류로 고치면 오히려 데이터를 오염시킵니다.

자료형 질문 리스트

적재 단계에서는 모든 값을 문자열로 두고, 계산·검사할 때만 표준사전 도메인(D001~D023) 규칙으로 숫자·일시·불리언으로 해석합니다. MySQL 스테이징 테이블도 값 컬럼은 VARCHAR입니다.

질문	우리 처리	이유
왜 숫자 컨럼까지 문자열로 읽나?	읽을 때는 문자열, 계산할 때만 변환	타입을 먼저 강제하면 "abc", "1.2.3" 같은 오염값이 로드 중 조용히 NaN이 되거나 에러로 멈춰, 무엇이 오염이었는지 기록을 못 남깁니다.
식별자(session_key, driver_number)는 숫자인가 문자인가?	문자열(D001), 공백 금지	계산하지 않는 값이고, 앞자리 0이나 자릿수가 바뀌면 JOIN이 어긋납니다.
빈 문자열을 0으로 바꿔도 되나?	안 됩니다. 결측은 결측으로 둡니다	0초 랩·0점은 실제 값처럼 평균에 섞입니다. VC03이 "결측을 0으로 채운 값"을 따로 검사합니다.
시간 길이는 무슨 단위·정밀도인가?	초 단위 실수, 소수 6자리, 음수 금지(D003)	랩·섹터·피트 시간을 같은 단위로 더하고 빼야 섹터 합계·시각 연속성 검사가 가능합니다.
날짜시간은 어떻게 해석하나?	ISO 8601, UTC 오프셋 포함(D008)	랩 시작 시각과 관제 메시지·기상 시각을 맞추려면 같은 시간대 기준이 필요합니다.
불리언은 어떤 표기를 허용하나?	True / False만(D009)	1/0, Y/N, yes 등이 섞이면 필터 결과가 달라집니다. 허용 외 표기는 DQ014 형식 위반입니다.
타이어 컴파운드는 자유 문자인가?	코드 6개: SOFT, MEDIUM, HARD, INTERMEDIATE, WET, UNKNOWN(D011)	대소문자·오타가 섞이면 같은 타이어가 다른 그룹으로 집계됩니다(VC32).
격차(gap_to_leader)는 숫자인가?	문자열: 초 단위 실수 또는 "+N LAP(S)"(D021)	랩 다운된 선수는 초가 아니라 랩 수로 표기되어, 숫자로 강제 변환하면 정보가 사라집니다.
미니 섹터 상태(segments_sector_1~3)는?	목록 문자열 원문 보존, JSON 임의 변환 금지(D012)	분석에 쓰지 않는 컨럼이고, 변환 과정에서 원문이 바뀔 수 있습니다.

질문	우리 처리	이유
포인트는 원천 값을 그대로 쓰나?	분석은 재계산한 race_base_points 사용	원천 points는 최속 랩 보너스가 섞여 최대 26점이고 누락도 있습니다. 재계산하면 87경기 모두 경기당 101점으로 맞습니다.
속도·온도·각도의 단위는?	속도는 원문 단위, 온도는 섭씨, 풍향은 0~360도, 습도는 0~100%	단위를 사전에 고정해 범위 검사(VC31)의 기준을 만듭니다.

데이터 처리 기준 질문 리스트

값을 고칠지는 "데이터 안에 다른 근거가 있는가"로 정합니다. 근거의 강도는 repair_confidence(HIGH·MEDIUM·LOW)로 남깁니다.

질문	처리 기준	이유
파일마다 meeting_key가 다르면 어느 쪽을 믿나? (DQ015)	같은 session_key의 하위 5개 파일이 가리키는 합의값으로 복구, HIGH	한 파일만 다르고 나머지가 일치하면 다른 쪽이 오염일 가능성이 높습니다. 정제 전 VC22가 9개 파일 48,406행에서 FAIL이었습니다.
드라이버 이름이 다른 차량번호와 바뀌면? (DQ016)	시즌 내 차량번호별 신원 합의값으로 교환, HIGH	차량번호는 시즌 내내 고정이라 다른 세션 기록이 근거가 됩니다. 20셀 복구.
팀명이 한 세션만 다르면? (DQ017)	앞뒤 세션 소속팀으로 복구. 단, 팀 색상이 원래 팀과 일치할 때만	실제 이적과 오염을 구분하려고 팀 색상을 두 번째 근거로 씁니다. 4셀 복구.
섹터 시간이 비어 있으면? (DQ004)	하나만 비었을 때 랩타임 − 나머지 두 섹터, HIGH. 둘 이상은 OPEN	식으로 계산되는 값만 채웁니다. 두 개 이상 비면 나눠 가질 근거가 없습니다. 489셀 복구, 1,000건 미해결.
랩타임이 비어 있으면? (DQ018)	다음 랩 시작 − 현재 랩 시작, MEDIUM. 1랩은 원천 특성 허용	시작 시각이 연속이면 차이가 곧 랩타임입니다. 1랩은 원래 기록되지 않는 경우가 많습니다.

질문	처리 기준	이유
랩 시작 시각이 어긋나면? (DQ019)	인접 랩 시각 교환 또는 랩 기록 통째 교환으로 복구	앞 랩 시작 + 랩타임 = 다음 랩 시작이라는 연속성이 근거입니다(VC46).
컴파운드가 비어 있으면? (DQ008)	UNKNOWN 코드 부여, LOW	실제 타이어를 추정한 것이 아니라 "모름"을 허용 코드로 표시한 것입니다. 분석에서는 건조 컴파운드만 씁니다.
스틴트 시작·종료 랩이 비면? (DQ009)	앞뒤 스틴트 경계나 랩 기록으로 복구, MEDIUM	스틴트는 끊김 없이 이어지므로 인접 경계가 근거입니다. 52셀 처리.
노면온도가 한 번만 튀면? (DQ023)	앞뒤 1분 측정값과 10도 이상 차이 나는 단일값은 앞뒤 평균, MEDIUM	노면온도는 1분 사이에 10도씩 변하지 않습니다. 5셀 복구.
국가코드·프로필 URL이 비면? (DQ001, DQ024)	같은 드라이버의 다른 세션 기록, 같은 시즌의 유일한 URL	선수에 고정된 속성이라 다른 기록을 그대로 쓸 수 있습니다.
속도값이 비면? (DQ003)	대체하지 않고 ACCEPTED	속도 트랩 통과 시 원래 측정 안 되는 원천 특성입니다 (24,101건).
수치가 이상하게 크면? (DQ006·007·022)	랩 300초, 피트 180초, 정지 10초 초과는 자동 수정 없이 검토	적기·사고로 실제 길어진 값일 수 있어, 오류로 단정하면 진짜 기록을 지웁니다.

예외처리 질문 리스트

예외는 세 갈래로 나눕니다. 원천 특성이면 허용(ACCEPTED), 근거가 없으면 미해결(OPEN), 분석을 왜곡하면 격리(quarantine_flag=Y)입니다.

질문	처리	이유
두 컨럼이 같아야 하는데 다르면? (DQ021 피트 lane_duration ≠ pit_duration)	격리 2행	어느 쪽이 맞는지 근거가 없습니다. 하나를 골라 고치면 절반 확률로 틀린 값을 만듭니다.
랩 시각이 여러 드라이버에서 동시에 어긋나면?	허용(같은 세션·같은 랩 ±1에서 2명 이상)	적기·체커 이후처럼 경기 전체에 일어난 사건입니다. 오염은 한 행에만 생깁니다.
랩 시각 차이가 아주 작으면?	3초 이내는 허용	원천 타이밍 오차 범위입니다.

질문	처리	이유
랩 시각이 혼자 크게 어긋나고 교환 근거도 없으면?	격리 2행(9181 #11 랩 2, 11353 #41 랩 6)	어느 값이 맞는지 알 수 없는데 페이스 계산에 들어가면 결과를 바꿉니다.
스틴트 종료가 시작보다 앞서면? (DQ010)	lap_end = lap_start − 1이면 허용(빈 스틴트), 그 외 격리	빈 스틴트는 원천에서 반복적으로 나오는 표기입니다(11건).
스틴트 구간이 겹치면? (DQ011)	같은 랩 경계 공유는 허용, 그 이상은 검토	피트 랩은 두 스틴트에 모두 걸쳐 기록됩니다.
모양이 아예 잘못된 값이면? (DQ014 형식 위반)	격리	숫자·일시·불리언으로 해석할 수 없으면 어떤 계산에도 쓸 수 없습니다.
같은 키가 두 번 나오면? (DQ026)	격리, 삭제하지 않음	어느 행이 진짜인지 모르고, 지우면 행 수 대사가 깨집니다. 정제 후 자연키 중복은 0건입니다.
상위 파일에 없는 키를 가리키면? (DQ027)	격리	연결할 경기·선수가 없는 행은 분석에 들어갈 자리가 없습니다.
구조·체크섬이 명세와 다르면? (DQ013)	파일 단위 FAIL, 실행 종료 코드 1	파일 자체가 바뀌었다면 행 단위 복구로는 믿을 수 없습니다.
복구하지 못한 오류가 남으면 파이프라인은?	ERROR 등급이면 FAIL로 멈춤, 그 외는 REVIEW로 진행	심각한 결함이 남은 채로 Gold가 만들어지지 않게 합니다. 리포트는 멈추기 전에 모두 씁니다.
원천의 결과 상태가 이상하면? (예: 순위 없음 + DNF·DNS·DSQ 모두 False)	WARN으로 남김(VC04 4건)	2023 오스틴 실격처럼 실제 사건이라 고칠 대상이 아닙니다.

격리 행도 repaired/에 남기고 quarantine/에 따로 저장합니다. 분석할 때는 quarantine_flag=Y를 제외합니다.

분석 단계 처리 기준 질문

정제된 데이터도 그대로 평균 내지 않고, 페이스를 공정하게 비교할 수 있는 랩만 골라 씁니다. 기준은 pipeline/driver_check.py와 후보 선정 보드(decision_board.json)가 같은 방향입니다.

질문	기준	이유
어떤 세션을 쓰나?	본경기(Race)만, 비 오는 경기 제외	예선·스프린트는 연료·전략이 다르고, 비는 랩타임을 크게 바꿉니다.
1랩과 피트 랩은?	모두 제외(1랩, 피트 인·아웃 랩)	출발 혼잡과 피트레인 주행이 선수 실력과 무관한 시간을 더합니다.
SC·VSC·적기 구간은?	race_control 시각으로 구간을 만들고, 종료 공지 후 120초까지 제외	전체가 감속하는 구간이고, 재개 직후도 타이어·간격이 정상이 아닙니다.
느린 랩(트래픽·실수)은?	선수별 그 경기 중앙값의 107% 초과 제외	한 번의 스핀이 평균을 끌어올리지 않게 합니다. F1의 예선 107% 규칙과 같은 발상입니다.
랩타임 범위는?	0초 초과 300초 이하, 격리 행 제외	DQ006 기준과 같습니다.
타이어는?	건조 컴파운드(SOFT·MEDIUM·HARD)만, 두 스틴트에 걸친 랩 제외	UNKNOWN과 우천용 타이어는 비교 기준이 다릅니다.
팀 동료와는 어떻게 짝짓나?	같은 경기·팀·랩·컴파운드, 타이어 나이 차 3랩 이하, 시작 시각 차 90초 이내, 경기당 8쌍 이상	차·타이어·트랙 상태를 최대한 같게 맞춰 선수 차이만 남깁니다.
평균은 어떻게 내나?	경기별 중앙값의 평균, 95% 구간은 경기 단위 부트스트랩 2,000회	랩이 많은 경기가 결과를 독점하지 않게 하고, 경기마다 다른 조건을 불확실성에 반영합니다.
결과가 정제 기준에 따라 바뀌지 않나?	기준을 11가지로 바꿔 모두 같은 방향일 때만 통과	한 가지 정제 선택에서만 나오는 결과는 우연일 수 있습니다. VERSTAPPEN은 10/11이라 탈락했습니다.
타이어 유지력은?	스틴트별 랩당 저하(ms/랩)에서 같은 경기·컴파운드 중앙값을 뺌, 8랩 이상·타이어 나이 폭 7 이상만	짧은 스틴트는 기울기가 잡음에 흔들립니다. 그래도 편차가 커서 순위 기준이 아니라 확인 과제로 둡니다.

발표 예상 질문 짧은 답변

예상 질문	짧은 답변	근거 위치
왜 결측을 평균·중앙값으로 채우지 않았나?	추정값이 섞이면 선수 비교 결과가 진짜 기록인지 구분할 수 없습니다. 근거 없는 결측은 OPEN으로 두고 분석에서 빼서 유효 표본 수를 함께 보여줍니다.	docs/03 §1-②
탐지 28,071건인데 복구는 1,357셀뿐인가?	24,866건은 원천 특성(속도 결측 24,101건 등)이라 고칠 대상이 아닙니다. 남은 1,848건은 근거가 없어 미해결로 둡니다.	docs/03 §2
행을 왜 삭제하지 않나?	원본 = 유지 + 복구 + 격리로 대사해 누락이 없음을 증명하기 위해서입니다(VC60 PASS).	docs/04 §2
복구가 맞다는 걸 어떻게 아나?	같은 검사를 정제 전·후에 돌려 FAIL 12건이 0이 됐고, pandas와 MySQL 결과가 154개 검사 모두 건수까지 일치합니다.	docs/04 §2
왜 모든 값을 문자열로 읽나?	오염값이 로드 중 조용히 사라지지 않게 하려는 것입니다. 해석은 검사 단계에서 도메인 규칙으로 합니다.	docs/02 §2
포인트를 왜 재계산했나?	원천 points에 최속 랩 보너스가 섞여 47행이 다릅니다. 재계산하면 경기당 101점으로 맞아 팀 비교가 공정해집니다.	docs/04 §2 INFO
격리 4행이 결과에 영향을 주나?	피트 2행·랩 2행이고 분석에서 제외합니다. 랩 97,018행 중 2행이라 페이스 비교에 미치는 영향은 작습니다.	docs/03 §2
정제 기준을 바꾸면 후보가 바뀌지 않나?	기준 11가지 모두에서 같은 방향인 선수만 통과시켰고, LECLERC·RUSSELL은 11/11입니다.	README ③, docs/06
WARN 7건은 왜 안 고쳤나?	실격·기권처럼 실제 사건이거나 원천 표기 방식이라 고치면 오히려 사실과 달라집니다.	docs/04 §2 WARN